

Sapiência
synthesis*

EBOOK DE RESUMOS

Analytics para Big Data

Autor: Juliana Padilha et al.

Editora: Grupo A

ISBN: 9786556903477

RESUMO POR:



Sumário Interativo

Os autores **3**

Pontos principais do livro **4**

Mindmap **6**

Resumo Escrito **8**

Big Data e Big Data Analytics **8**

Ciclo de vida da análise de dados **8**

Self-Service Analytics **9**

Visualização de Dados **10**

Implementação OLAP **10**

Linguagem R **10**

MapReduce **11**

Integração entre R e Hadoop **12**

Análise de Texto e Extração da Web **12**

APIs **13**

Big Data Analytics no mundo dos negócios **14**



O autor

Pontos principais do livro

Mindmap

Resumo Escrito

- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios

Os autores

Juliana Padilha

Mestra em Ciência da Computação com ênfase em Engenharia de Software

Juliane Adélia Soares

Especialista em Perícia Forense Digital

Nicolli Souza Rios Alves

Doutora em Ciência da Computação

Eduardo Melione Abreu

Mestre em Engenharia de Sistemas e Computação
Especialista em Big Data

Fernanda Rosa da Silva

Especialista em Cloud Computing

Myllena Silva de Freitas Moraes

Graduada em Licenciatura em Computação

Paulo Sérgio Pádua de Lacerda

MBA em Tecnologia e Internet

Roque Maitino Neto

Mestre em Ciência da Computação

Victor de Andrade Machado

Mestre em Engenharia Elétrica na área de Computação Aplicada



O autor

Pontos principais do livro

Mindmap

Resumo Escrito

- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios

Pontos principais do livro

- Neste volume, você será introduzido aos princípios de análise para big data, entenderá as etapas do ciclo de vida da análise de dados e aprenderá a coletar informações através do analytics de autoatendimento.
- Também serão discutidos elementos e estratégias utilizados na visualização de dados, técnicas para a implementação de OLAP, métodos de análise de dados usando a linguagem R, bem como o modelo MapReduce e técnicas para o consumo de conjuntos de dados.
- Adicionalmente, Análise para Big Data explora a combinação entre R e Hadoop para cálculos estatísticos em big data, a aplicação de análise na interpretação de texto, o uso de algoritmos e métodos para extração de informação da web, o desenvolvimento de rastreadores web e a aplicação da análise de big data nos negócios.
- O material do livro é projetado para auxiliar vários interessados neste processo: analistas de negócios e dados, profissionais de banco de dados e gerentes de inteligência empresarial, analistas ou grupos de estudo de big data que buscam aprimorar suas habilidades analíticas, e estudantes universitários que desejam se especializar em ciência de dados.



O autor

Pontos principais do livro

Mindmap

Resumo Escrito

- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios



Analytics para big data.

PADILHA, Juliana; SOARES, Juliane A.; ALVES, Nicolli S R.; et al. 2022



Mindmap



- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios

Resumo Escrito

Big Data e Big Data Analytics

No primeiro texto do livro, Juliane Adélia Soares oferece uma introdução abrangente ao conceito de Big Data e Big Data Analytics. Ela define Big Data como conjuntos de dados cujo volume, velocidade e variedade são tão grandes que tornam difícil seu armazenamento, gerenciamento, processamento e análise com uso de banco de dados e ferramentas de processamento tradicionais. Ela explica que Big Data Analytics é o processo usado para extrair insights importantes desses dados, como padrões ocultos. A análise pode ser descritiva, diagnóstica, preditiva ou prescritiva. Cada tipo de análise tem suas próprias características e aplicações, permitindo aos profissionais escolher a abordagem mais adequada para suas necessidades específicas. Além disso, Soares discute a diferença entre Data Science e Business Intelligence. Embora ambos os campos estejam relacionados à Big Data Analytics, eles têm diferenças significativas em termos de abordagens e objetivos. A Data Science é uma combinação de diversos campos para extração de valores de dados, incluindo estatística, métodos científicos, inteligência artificial e análise de dados. Por outro lado, Business Intelligence é uma combinação de coleta e armazenamento de dados, além de gerenciamento de conhecimento, para avaliação e transformação de dados complexos em informações significativas..

Ciclo de vida da análise de dados

Victor de Andrade Machado descreve as fases do ciclo de vida da data analytics. Ele explica que essas fases são organizadas em uma estrutura circular e incluem descoberta de dados, preparação de dados, planejamento de um modelo, exploração de dados e seleção de variáveis, seleção do modelo, construção de um modelo, publicação

- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios

dos resultados e operacionalização.

Cada fase tem suas próprias características e atividades específicas que contribuem para o processo geral de análise de dados. A descoberta de dados envolve a definição da finalidade dos seus dados e como alcançá-la quando chegar ao final do ciclo de análise de dados. A preparação dos dados envolve a coleta, o processamento e a limpeza dos dados acumulados. O planejamento do modelo requer a disponibilidade de uma sandbox analítica para que a equipe trabalhe com os dados e execute análises durante toda a duração do projeto. A exploração dos dados e a seleção das variáveis envolvem a compreensão das relações entre as variáveis para facilitar a seleção das variáveis relevantes e dos métodos apropriados. A seleção do modelo envolve a escolha da técnica analítica ou uma pequena lista de técnicas candidatas com base no objetivo final do projeto. A construção do modelo envolve o desenvolvimento dos conjuntos de dados para teste, treinamento e produção. Por fim, a publicação dos resultados envolve a comunicação da análise dos dados aos clientes interessados.

Self-Service Analytics

Juliane Adélia Soares discute o conceito de Self-Service Analytics. Ela destaca que este método permite que usuários empresariais realizem coletas e análises de dados de diferentes fontes em tempo real, sem necessitar do auxílio de especialistas no ramo. A importância da self-service analytics na era digital é destacada por Soares, assim como as estratégias para sua implementação eficaz. Ela argumenta que a self-service analytics é ideal para a geração rápida de insights aos negócios na era digital. Além disso, ela discute a necessidade de treinamento para o uso eficaz de self-service analytics, a importância da alfabetização na área de dados, a necessidade de dados confiáveis e o equilíbrio entre autoatendimento e governança de TI.

- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios

Visualização de Dados

Juliana Padilha aborda a importância de contar histórias com dados e as técnicas para fazê-lo efetivamente. Ela explica a diferença entre análise exploratória e análise explanatória. A análise exploratória é usada para entender e se familiarizar com os dados e gerar informações, enquanto a análise explanatória é usada quando se encontra algo interessante nos dados e se deseja saber mais sobre isso. Padilha apresenta técnicas de visualização de dados e discute o conceito de saturação em visualização de dados. Ela também discute os diferentes tipos de gráficos utilizados para visualizar dados e como a escolha do tipo de gráfico pode afetar a interpretação dos dados.

Implementação OLAP

Nicolli Souza Rios Alves explora as técnicas para implementação de OLAP. Ela começa destacando que os ambientes que apoiam as tomadas de decisões sobre os negócios de uma empresa são caracterizados, principalmente, como somente leitura. Isso significa que os dados são principalmente consumidos e não alterados. Alves então mergulha na implementação de OLAP, explicando que pode ser feita por índices de mapas de bits (bitmap index), por índices de junção (join index) e por organizações de arquivo (file organization). Cada uma dessas técnicas tem suas próprias vantagens e desvantagens, e a escolha entre elas depende das necessidades específicas do sistema. Alves argumenta que para facilitar a busca dos dados em DW, podem ser utilizadas algumas técnicas de implementação baseadas em índices ou na organização dos arquivos. Essas técnicas ajudam a melhorar a eficiência e a velocidade das consultas OLAP.

- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios

Linguagem R

Eduardo Melione Abreu introduz a linguagem R e suas características. Ele começa explicando que R é uma linguagem de programação criada sob a aura do software livre, que tem como principal finalidade a aplicação em casos de computação que requerem uso de estatística e visualização gráfica. A linguagem tem ampla utilização na comunidade acadêmica e científica, com mais adeptos ao longo dos anos para realização de atividades de mineração de dados e analytics. Abreu então discute o uso do ambiente integrado de desenvolvimento R Studio para facilitar o desenvolvimento das atividades de análise. Ele explica que o R Studio oferece uma interface amigável para escrever código R e visualizar os resultados. Abreu também aborda a análise exploratória de dados em R, incluindo o uso do método clustering com o algoritmo K-Means, a análise da variação e a identificação de outliers. Ele explica que essas técnicas permitem aos analistas entender os padrões nos dados e fazer previsões precisas.

MapReduce

Paulo Sérgio Pádua de Lacerda introduz o conceito do MapReduce para processamento em big data. Ele explica que o MapReduce é um modelo de programação paralela e distribuída projetado para ser executado em ambiente de alta disponibilidade e confiabilidade, como o Hadoop. Lacerda discute a estrutura básica do MapReduce, os tipos de tarefas que ele é capaz de cumprir e os padrões computacionais adotados por esse modelo de programação. Ele também aborda a entrada de dados, a implementação do Mapper, Combiner, Partitioner, Shuffle and Sort, e Reducer no MapReduce. Além disso, ele discute os diferentes tipos de jobs do MapReduce e os padrões usados pelo MapReduce. Ele destaca que o MapReduce é uma ferramenta capaz de analisar grandes conjuntos de dados de forma que os resultados possam ser utilizados por grandes corporações e aplicados em inovações, novos mercados e planejamento estratégico.

- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios

Integração entre R e Hadoop

No oitavo capítulo, Roque Maitino Neto discute a integração entre R e Hadoop para computação estatística em big data. Ele argumenta que R e Hadoop formam uma combinação perfeita para as finalidades de big data. Neto explica que as ferramentas R e Hadoop, quando combinadas, formam um recurso incomparável de processamento para controle de grande quantidade de dados e para a análise e visualização de dados estatísticos. Ele apresenta diferentes opções para essa integração, incluindo a instalação do R nas estações de trabalho e sua conexão com os dados do Hadoop, a instalação do R em um servidor compartilhado e sua conexão com o Hadoop, e a execução do R dentro do Hadoop MapReduce com o RHIFE. Ele também discute soluções para otimizar a integração entre R e Hadoop usando o RHadoop.

Análise de Texto e Extração da Web

Fernanda Rosa da Silva, aborda a análise de texto e a extração de informações da web, incluindo o uso de APIs. A análise de texto é necessária para transformar dados não estruturados em dados estruturados. A mineração de texto é uma extensão da mineração de dados, mas usa dados semiestruturados e não estruturados. As APIs são uma espécie de ponte que permite aos desenvolvedores utilizar facilmente o código de outros desenvolvedores/empresas. Elas são particularmente úteis para coletar dados de plataformas de mídia social como o Twitter. O protocolo Open Authorization (OAuth) é comumente usado por todas as principais mídias sociais. Ele permite que os usuários compartilhem dados com um aplicativo sem precisarem compartilhar sua senha. O Twitter é uma plataforma de mídia social amplamente utilizada para fins de pesquisa e análise de mercado.

- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios

A análise de tweets ajuda as empresas a entender o que seu público-alvo pensa sobre seus produtos ou serviços, facilitando a tomada de decisões baseada em dados reais. Um web crawler é um software ou script automatizado que indexa dados em páginas da web. O objetivo principal de um web crawler é saber do que tratam as páginas da web, permitindo que os usuários recuperem qualquer informação em uma ou mais páginas quando necessário. Os web crawlers estão sempre procurando links detectáveis nas páginas e os anotando em seus mapeamentos assim que entendem seus recursos. Eles só fazem esse vasculhamento nas páginas públicas dos sites. Os web crawlers são essenciais para fornecer informações atualizadas sobre o número de sites adicionados à web. Diversos mecanismos de busca fazem uso de web crawlers para armazenar as páginas mais visitadas de um site, que são processadas para uso posterior.

APIs

O Capítulo 10, escrito por Juliana Padilha, explora a importância das APIs e como elas são usadas para extrair informações, especialmente de plataformas de mídia social como o Twitter. Uma API é um elemento que promove uma ligação física ou lógica entre dois elementos de software ou partes de um software que não poderiam ser conectados diretamente sem ela. As APIs têm sido amplamente utilizadas na indústria de software quando há a necessidade de um software diferente trocar dados com outros. O protocolo Open Authorization (OAuth, ou autorização aberta), comumente utilizado por todas as principais mídias sociais, permite que os usuários compartilhem dados com um aplicativo sem precisarem compartilhar senha. Essa é uma forma de obter um esquema de autorização segura que é fundamentada em um mecanismo de autorização baseado em token. A API Tweepy, implementada na linguagem Python, é uma biblioteca popular entre os desenvolvedores para coletar dados do Twitter. Ela é fácil de usar e muito eficiente. As empresas de mídias sociais como Facebook, Twitter, Instagram e YouTube têm livre-arbítrio para definirem se oferecerão ou não uma API e se terceiros terão acesso aos seus dados armazenados e até mesmo se

- Big Data e Big Data Analytics
- Ciclo de vida da análise de dados
- Self-Service Analytics
- Visualização de Dados
- Implementação OLAP
- Linguagem R
- MapReduce
- Integração entre R e Hadoop
- Análise de Texto e Extração da Web
- APIs
- Big Data Analytics no mundo dos negócios

esse acesso será gratuito ou pago. Desse modo, para o usuário/desenvolvedor descobrir que tipo de informação cada empresa permite que ele utilize, precisa conferir documentação de cada uma delas.

Big Data Analytics no mundo dos negócios

Myllena Silva de Freitas Moraes explora o papel crucial do Big Data Analytics no mundo dos negócios. O Big Data Analytics é uma tecnologia que gerencia grandes volumes de dados capturados de várias maneiras. Esses dados, quando analisados, podem revelar padrões e insights valiosos que auxiliam as organizações em seu processo de tomada de decisão.

A autora também discute as técnicas de mineração de dados, um processo importante dentro do estudo da ciência dos dados. Essas técnicas envolvem a aplicação de tecnologias da informação, avaliação de padrões por meio de dados e descoberta automática. A mineração de dados é um processo analítico que explora grandes quantidades de dados em busca de padrões consistentes e/ou relacionamentos sistemáticos entre variáveis.

Após a mineração de dados, a próxima etapa é implementar a análise para uso real. Isso permite que os resultados da mineração sejam aplicados de maneira prática, gerando lucros para a empresa. Durante esse processo de implantação, é crucial envolver os membros da equipe de desenvolvimento desde o início do projeto. Isso ajuda a evitar a transferência de dados inconsistentes ou errados e garante uma operação segura.

The background of the image is a dark purple gradient. Overlaid on this are two abstract network diagrams. One is in the top right corner, featuring a cluster of nodes connected by thin, light purple lines. The other is in the bottom left corner, showing a more dispersed network of nodes and lines. The text 'Sapiência' is in a light orange color, and 'synthesis' is in white. A small orange asterisk is positioned above the 'i' in 'synthesis'.

Sapiência
synthesis*